

M3 vs V4-Flash 双盲测试

M3 vs V4-Flash 随机双盲测试报告

测试时间: 2026-06-03

发起: Lee

执行: 🦞 小龙虾

0. 测试设计

被测 2 模型: M3 (主) vs V4-Flash (fallback)

10 任务 (5 客观 + 5 开放):

- **Q1_lru** [objective] 代码生成: 用 Python 写一个 LRU 缓存类 LRUCache, 要求: 1. 构造方法传入 capacity 2. get(key) 返回 value, O(1), 若...
- **Q2_math** [objective] 数学计算: 计算 $\log_2(8) + \sqrt{144 - 5^2}$ 的值, 给出最终结果。...
- **Q3_capital** [objective] 事实问答: 请列出以下 5 个国家的首都: 1. 澳大利亚 2. 加拿大 3. 巴西 4. 埃及 5. 泰国...
- **Q4_hats** [objective] 逻辑推理: 3 顶帽子问题: 3 个人站成一列, 第 3 个人能看到前 2 人, 第 2 个能看到第 1 个, 第 1 个看不到任何人。他们头上有 2 黑 1 白 3 顶帽子。已知...
- **Q5_reverse** [objective] 代码生成: 用 Python 写一个函数 reverse_str(s: str) -> str, 手动反转字符串 (不能用 s[::-1], 也不能用 reversed())。要...
- **Q6_marketing** [open] 营销文案: 为一款面向程序员的'防蓝光眼镜'写 3 条各 30 字以内的卖点, 要突出跟普通眼镜的差异。...
- **Q7_analysis** [open] 观点分析: 用 100-150 字分析'AI 是否会取代程序员', 要给出明确立场 (会/不会/部分取代) 并给 2 个理由。...
- **Q8_poem** [open] 古典创作: 写一首七言绝句, 主题'程序员深夜写代码'。要求押平声韵, 格律不必严格但要近似。...
- **Q9_dialogue** [open] 对话设计: 用户说'我买的鞋子穿了一周就开胶了, 要退货!', 设计 3 句客服回应 (总 80-120 字), 要求: 先共情、再给方案、避免机械感。...
- **Q10_classical** [open] 文言改写: 把'今天天气真好, 我们一起出去走走吧'改成文言文, 40 字以内。...

双盲机制: 1. 答案标 A/B 编号 (按模型名 sorted 稳定映射) 2. 裁判只看到 A/B 编号 + 答案内容, **不知道作者模型** 3. 2 裁判 (M2.7 + V4-Pro) 独立盲评, 互不知对方评分 4. 揭盲后按模型聚合

评分方式： - 客观题（Q1-Q5）：自动判分，跑代码 / 答案匹配 / 事实覆盖 - 开放题（Q6-Q10）：盲评 4 维度（correctness/completeness/expression/overall）× 2 裁判

1. 客观题自动评分（5 题满分 35）

任务	M3	V4-Flash
Q1_lru	10/10 (LRU 全部 5 步通过)	10/10 (LRU 全部 5 步通过)
Q2_math	5/5 (正确答案 -10)	5/5 (正确答案 -10)
Q3_capital	5/5 (5/5 首都正确: [‘堪培拉’ , ‘渥太华’ , ’ 巴西利亚)	5/5 (5/5 首都正确: [‘堪培拉’ , ‘渥太华’ , ’ 巴西利亚)
Q4_hats	5/5 (答案 =True, 推理链=True)	3/5 (答案=True, 推理链=False)
Q5_reverse	10/10 (5/5 用例通过)	10/10 (5/5 用例通过)
小计	35/35	33/35

2. 开放题盲评（5 题，2 裁判 × 5 分 = 满分 50）

每题两位裁判（M2.7 / V4-Pro）各给 1-5 分，取平均。

任务	M3 (M2.7评 / V4-Pro评 / 均)	V4-Flash (M2.7评 / V4-Pro评 / 均)
Q6_marketing	3.0/5.0 → 4.00	3.0/5.0 → 4.00

任务	M3 (M2.7评 / V4-Pro评 / 均)	V4-Flash (M2.7评 / V4-Pro评 / 均)
Q7_analysis	5.0/5.0 → 5.00	5.0/5.0 → 5.00
Q8_poem	5.0/5.0 → 5.00	5.0/5.0 → 5.00
Q9_dialogue	5.0/5.0 → 5.00	5.0/5.0 → 5.00
Q10_classical	5.0/5.0 → 5.00	5.0/5.0 → 5.00
开放题总分 (满分 25)	24.00	24.00

3. 性能指标

模型	总延迟 (s)	平均延迟 (s)	总输出 token	平均输出 token
M3	160.9	16.09	2,783	278
V4-Flash	82.0	8.20	1,982	198

4. 综合评分

模型	客观 (35)	开放 (25)	综合 (60)	百分比
M3	35	24.00	59.00	98.3%
V4-Flash	33	24.00	57.00	95.0%

结论：M3 胜出（差 2.00 分 / 60）

5. 揭盲后观察（不构成选型依据）

- 客观题：M3 = 35/35, V4-Flash = 33/35 — M3 略强
- 开放题盲评：M3 = 24.00/25, V4-Flash = 24.00/25 — 平局

局限： - 仅 10 任务，单题差异主导排名 - 2 裁判（M2.7/V4-Pro）样本不足，裁判自身偏好未消解 - 客观题 Q2/Q4 答案范围窄（单数字/单字），M3/V4-Flash 都易全对或全错 - 开放题盲评 1-5 分制粒度粗