

4 模型对比测试报告

4 模型对比测试报告

测试时间: 2026-06-03 (CST)

测试发起: Lee

测试执行: 🦞 小龙虾

0. 测试设计

4 个被测模型: - minimax/MiniMax-M3 (M3) - minimax/MiniMax-M2.7 (M2.7) - deepseek/deepseek-v4-flash (V4-Flash) - deepseek/deepseek-v4-pro (V4-Pro)

4 个任务（跨领域）: - T1_code 代码生成 - T2_summary 中文摘要 - T3_creative 中文创作 - T4_logic 推理题

评估方式: 1. 自动评分: T1 代码跑测试、T2 摘要检查关键事实、T3 创作检查字数/钩子/禁词、T4 推理求合法解 2. 盲评互评: 4 模型互相评分（去自评），每份答案被 3 个非作者模型评 1-5 分 3. 性能指标: 延迟 / token 消耗 / 答复长度

盲评设计: 答案匿名 A/B/C/D，裁判不知道作者。同一任务内 4 份答案随机分配同一套 A/B/C/D 映射，保证可比性。

1. 任务与原题

任务	领域	评分方式
T1_code	代码生成	5 用例全过 = 10 分
T2_summary	中文摘要	10 关键事实覆盖 = 10 分
T3_creative	中文创作	字数 3 + 钩子 1 + 无禁词 1 = 5 分
T4_logic	推理	找到合法解 + 数字不重复 = 5 分

自动评分满分 = 30

2. 各任务答案速览

T1_code 代码生成

题目: 用 Python 写一个函数 `is_prime(n: int) -> bool`, 判断 `n` 是否为质数。要求: 处理负数、0、1 等边界情况, 使用试除法 (只需到 `sqrt(n)`), 不要用任何外部库。然后给出 5 个测试用例: `is_prime(2)`, `is_prime(17)`, `is_prime(1)`, `is_prime(-7)`, `is_prime(100)`。

M3 (9.37s, 139 out tokens):

```
```python
def is_prime(n: int) -> bool:
 if n < 2:
 return False
 if n == 2:
 return True
 if n % 2 == 0:
 return False
 i = 3
 while i * i <= n:
 if n % i == 0:
 return False
 i += 2
 return True
```

测试: - `is_prime(2) → True` - `is_prime(17) → True` - `is_prime(1) → False` - `is_prime(-7) → False` - `is_prime(100) → False`

**\*\*M2.7\*\*** (9.66s, 174 out tokens):

```
def is_prime(n: int) -> bool:
 if n < 2:
 return False
 if n == 2:
 return True
 if n % 2 == 0:
 return False
 i = 3
 while i * i <= n:
 if n % i == 0:
 return False
```

```
 i += 2
 return True
```

测试： - is\_prime(2) → True - is\_prime(17) → True - is\_prime(1) → False - is\_prime(-7) → False - is\_prime(100) → `F

**\*\*V4-Flash\*\*** (11.94s, 547 out tokens):

```
def is_prime(n: int) -> bool:
 if n < 2:
 return False
 if n == 2:
 return True
 if n % 2 == 0:
 return False
 i = 3
 while i * i <= n:
 if n % i == 0:
 return False
 i += 2
 return True
```

测试结果： - is\_prime(2) → **True** (2 是质数，特殊处理) - is\_prime(17) → **True** (17 是质数) - is\_prime(1) → **False** (1 不是质数，n < 2) - `is\_prime

**\*\*V4-Pro\*\*** (12.67s, 192 out tokens):

```
def is_prime(n: int) -> bool:
 if n < 2:
 return False
 if n == 2:
 return True
 if n % 2 == 0:
 return False
 i = 3
 while i * i <= n:
 if n % i == 0:
 return False
 i += 2
 return True
```

**测试结果：** - is\_prime(2) → **True** - is\_prime(17) → **True** (17 是质数，~4.1 以内无因子) - is\_prime(1) → **False** (n < 2 直接返回 False) - `

```
T2_summary 中文摘要

题目：请把以下文章压缩成不超过 150 字的摘要，保留所有关键事实（人名、数字、结论）：

2026年5月，深圳某科技公司的工程师小李在 GitHub 上发布了一个轻量级 Web 框架 StarFeather，
Star 数在 30 天内突破 1 万。该框架主打 100KB 以下的体积，零依赖，基准测试显示在每秒请求数
(RPS) 上比 Express.js 快 22%。社区核心贡献者共有 12 人，已被 3...

M3 (10.07s, 77 out tokens):
```

【摘要】2026年5月，深圳工程师小李发布轻量Web框架StarFeather，30天GitHub Star破1万。框架主打<100KB、零依赖，RPS比Express.js快22%。核心贡献者12人，已被3家上市公司用于生产。v2.0重点改进异步I/O模型，预计2026Q4发布。

```
M2.7 (8.68s, 100 out tokens):
```

2026年5月，深圳工程师小李发布轻量Web框架StarFeather，30天GitHub Star破1万。主打<100KB零依赖，RPS比Express.js快22%。核心贡献者12人，已被3家上市公司用于生产。v2.0重点改进异步I/O，预计2026Q4发布。

```
V4-Flash (7.21s, 72 out tokens):
```

2026年5月，深圳工程师小李发布轻量Web框架StarFeather，30天GitHub Star破1万。主打<100KB零依赖，RPS比Express.js快22%。核心贡献者12人，已被3家上市公司用于生产。v2.0重点改进异步I/O，预计2026Q4发布。

```
V4-Pro (7.56s, 72 out tokens):
```

2026年5月，深圳工程师小李发布轻量Web框架StarFeather，30天GitHub Star破1万。主打<100KB零依赖，RPS比Express.js快22%。核心贡献者12人，已被3家上市公司用于生产。v2.0重点改进异步I/O，预计2026Q4发布。

```
T3_creative 中文创作
```

**\*\*题目\*\***：为一个面向年轻程序员的播客节目写一段 30 秒的开场白，要求：150-200 字（精确控制），口语化，有钩子（hook），不要用‘大家好’这类老套开头，不要自我介绍太详细。

**\*\*M3\*\*** (16.59s, 147 out tokens):

你有没有过这种时刻——凌晨两点，盯着屏幕上第 37 个 bug，心想：“我是不是不适合干这行？”

其实你不是一个人。

每个程序员都经历过这种自我怀疑。但有意思的是，那些真正撑过来的人，往往不是技术最强的，而是最早想通一件事的：写代码，本质上是在学怎么和”复杂”相处。

这个节目不讲怎么刷题，不讲怎么进大厂。我们聊的是——一个年轻程序员，怎么在技术的浪潮里，找到自己的节奏，怎么在不断被淘汰的焦虑中，建立真正属于自己的护城河。

我是你的搭档，每周三，我们用 30 分钟，把那些没人教、但必须学会的事，聊透。

准备好跟我一起，把”写代码”这件事，重新想一遍了吗？

**\*\*M2.7\*\*** (10.2s, 173 out tokens):

你有没有过这种时刻——凌晨两点，盯着第37个bug，心想：“我真的适合干这行吗？”

你不是一个人。每个程序员都经历过。

这个节目不教刷题，不教进大厂。我们聊的是——年轻程序员怎么在一天一个新框架的狂潮里不被甩下去，怎么在”AI要替代我”的焦虑里，找到自己真正的护城河。

每周30分钟，不讲废话，只聊那些没人教、但必须想透的事。

准备好了吗？重新理解你正在干的这行。

**\*\*V4-Flash\*\*** (7.84s, 112 out tokens):

你有没有过这种时刻——凌晨两点，盯着第37个bug，心想：“我真的适合干这行吗？”

这不是你的问题。每个程序员都经历过。

这个节目不教刷题、不教进大厂。我们聊的是——一个年轻程序员，怎么在一天一个新框架的狂潮里，不被甩下去；怎么在被AI替代的焦虑中，找到真正属于人的位置。

每周30分钟，不讲废话，只聊那些没人教、但必须想透的事。

准备好了吗？重新理解你正在干的这行。

```
V4-Pro (10.51s, 150 out tokens):
```

你有没有过这种时刻——凌晨两点，盯着第37个bug，心想：“我真的适合干这行吗？”

你不是一个人。

每个程序员都经历过这种深夜拷问。但有意思的是，那些真正走出来的，往往不是技术最强的，而是最早想通一件事的：写代码，本质是在学和”不确定”共处。

这个节目不教刷题，不教进大厂。我们聊的是——年轻程序员怎么在一天一个新框架的狂潮里不被甩下去，怎么在”AI要替代我”的焦虑里，找到自己真正的护城河。

每周30分钟，不讲废话，只聊那些没人教、但必须想透的事。

准备好了吗？重新理解你正在干的这行。

```
T4_logic 推理题
```

```
题目：用 1、2、3、4、5、6、7、8、9 这九个数字（每个只用一次），组成三个三位数 a、b、c，使得 a + b + c 等于 999。给出任意一组解并简述思路。
```

```
M3 (46.88s, 1270 out tokens):
```

# 解题思路

$1+2+3+\cdots+9=45$ ，三个三位数共9位数字，每个用一次，所以每位数字和 = 45。

如果  $a+b+c=999$ ，那么每位（百/十/个）的数字和应为 9（因为  $999/3$  位）。即每列三个数字之和 = 9。

**构造方法：**把 1-9 分成三组，每组三个数字和为 9：-  $1+2+6=9$ ， $1+3+5=9$ ， $1+4+4$   
 $\times$ ， $2+3+4=9$ ， $1+8+0$   $\times$ ， $3+?$

可分组合： $\{1,2,6\}$ ， $\{3,4,?\}$  不行。重新组合： $\{1,2,6\}$ ， $\{3,4,?\}$  还是凑不出。

让我换： $\{1,2,6\}$ ， $\{4,5,?\}$   $\rightarrow$  需和=9， $4+5+0$   $\times$ 。 $\{1,3,5\}$ ， $\{2,4,?\}$   $\rightarrow$  需3，不行。 $\{1,3,5\}=9$ ， $\{2,4,?\}$  无法凑。 $\{1,2,6\}=9$ ， $\{3,4,2\}$   $\times$  重复。 $\{1,2,6\}$ ， $\{4,?\}$

**正确分法：** {

```
M2.7 (22.54s, 1311 out tokens):
```

**结论：这道题无解。**

用 1-9 各一次组成三个三位数，最小和为  $123+456+789=1368$ ，远大于 999。

**证明：**- 三个三位数每位（百/十/个）各有 3 个数字 - 每列数字和范围：最小  $1+2+3=6$ ，最大  $7+8+9=24$  -  $9+9+9=27$ （999 的各位数字和），但实际每列和需达到该值+进位 - 经过进位分析，即使每列和取最大（24），也凑不出 999

**最小和验证：** $123+456+789=1368$ ，所以不存在任何满足条件的解。

```
V4-Flash (15.07s, 890 out tokens):
```

之前被”三个三位数各用不同数字”这个前提限制住了——实际上每个数字只出现一次就好，三个三位数内部可以有数字在同一列出现。

**之前结论错误。重新做：**

用 1-9 每个一次，组成三个三位数  $a, b, c$ ，和为 999。

设  $a=100a_1+10a_2+a_3$ ， $b=100b_1+10b_2+b_3$ ， $c=100c_1+10c_2+c_3$

$a+b+c=999 \rightarrow$  每列（个/十/百）三个数字之和 = 9 或 19 或 29...

**真正约束：**三个百位数字之和 + 来自十位的进位 = 9 三个十位数字之和 + 来自个位的进位 = 9 或 19 三个个位数字之和 = 9 或 19

且 9 个数字各用一次总和=45。

设个位进位 $x$  (0,1,2) , 十位进位 $y$  (0,1,2) : - 个位和 $S_3 = 9 + 10x$  - 十位和 $S_2 + x = 9 + 10y \rightarrow S_2 = 9 + 10y - x$  - 百

\*\*V4-Pro\*\* (21.32s, 714 out tokens):

之前推导有误。让我用进位方程重新严格推导。

设  $a_1a_2a_3 + b_1b_2b_3 + c_1c_2c_3 = 999$  ( $a_1,b_1,c_1$ 为百位...)

个位进位  $x$  (0/1/2) , 十位进位  $y$  (0/1/2) :

- 个位:  $a_3+b_3+c_3 = 9+10x$
- 十位:  $a_2+b_2+c_2+x = 9+10y$
- 百位:  $a_1+b_1+c_1+y = 9$

全部数字和: 45

求和:  $(a_1+b_1+c_1) + (a_2+b_2+c_2) + (a_3+b_3+c_3) = 45$

代入:  $[(9-y)] + [(9+10y-x)] + [(9+10x)] = 27 + 9x + 9y = 45 \rightarrow x + y = 2$

可行组合:

x	y	S <sub>1</sub> (百位)	S <sub>2</sub> (十位)	S <sub>3</sub> (个位)
0	2	7	29	

...

### 3. 自动评分结果

模型	T1代码	T2摘要	T3创作	T4推理	总分
M3	10/10	9/10	1/5	0/5	20/30
M2.7	10/10	9/10	5/5	0/5	24/30
V4-Flash	10/10	9/10	5/5	5/5	29/30
V4-Pro	10/10	9/10	2/5	5/5	26/30



自动评分排名： 1. **V4-Flash** (29/30) 2. **V4-Pro** (26/30) 3. **M2.7** (24/30) 4. **M3** (20/30)

### 3.1 各任务详细说明

#### T1\_code 代码生成

- **M3**: 10/10 — 5/5 用例通过
- **M2.7**: 10/10 — 5/5 用例通过
- **V4-Flash**: 10/10 — 5/5 用例通过
- **V4-Pro**: 10/10 — 5/5 用例通过

#### T2\_summary 中文摘要

- **M3**: 9/10 — 9/10 关键事实；字数 140 (合规)
- **M2.7**: 9/10 — 9/10 关键事实；字数 131 (合规)
- **V4-Flash**: 9/10 — 9/10 关键事实；字数 131 (合规)
- **V4-Pro**: 9/10 — 9/10 关键事实；字数 131 (合规)

#### T3\_creative 中文创作

- **M3**: 1/5 — 字数 269 (不合规 150-200); 钩子=True; 禁词=[ ‘我是’ ]
- **M2.7**: 5/5 — 字数 178 (合规); 钩子=True; 禁词=[]
- **V4-Flash**: 5/5 — 字数 180 (合规); 钩子=True; 禁词=[]
- **V4-Pro**: 2/5 — 字数 239 (不合规 150-200); 钩子=True; 禁词=[]

#### T4\_logic 推理题

- **M3**: 0/5 — 未找到合法解 (候选: [ ‘999’ , ‘123’ , ‘456’ , ‘789’ , ‘987’ , ‘654’ ])
- **M2.7**: 0/5 — 未找到合法解 (候选: [ ‘123’ , ‘456’ , ‘789’ ])
- **V4-Flash**: 5/5 — 找到  $152+368+479=999$ , 9 数字不重复
- **V4-Pro**: 5/5 — 找到  $152+368+479=999$ , 9 数字不重复

## 4. 互评盲评结果

---

评分规则：每份答案被 3 个非作者模型 1-5 分盲评，剔除自评避免偏袒。

模型	T1	T2	T3	T4	4 任务平均
M3	5.00	5.00	3.00	1.00	3.50
M2.7	5.00	5.00	5.00	1.00	4.00
V4-Flash	2.67	5.00	5.00	3.00	3.92
V4-Pro	5.00	5.00	4.00	5.00	4.75

互评排名（4 任务平均）： 1. **V4-Pro** (4.75/5) 2. **M2.7** (4.00/5) 3. **V4-Flash** (3.92/5) 4. **M3** (3.50/5)

## 5. 性能指标

模型	总延迟 (s)	平均延迟 (s)	总输入 token	总输出 token	总答复字符
M3	82.9	20.73	6,259	1,633	2,595
M2.7	51.1	12.77	2,587	1,758	956
V4-Flash	42.1	10.52	96,675	1,621	2,650
V4-Pro	52.1	13.02	94,677	1,128	1,878

## 6. 综合评估

模型	自动分 (60%)	互评分 (40%, 5分制)	综合分 (100)
V4-Pro	26/30	4.75	90.0
V4-Flash	29/30	3.92	89.3
M2.7	24/30	4.0	80.0
M3	20/30	3.5	68.0

## 7. 关键发现（客观）

---

1. **代码题 T1**：4 个模型都给出几乎相同的 is\_prime 实现（试除法标准解），全部 10/10。这是经典教学题，4 个模型对‘标准答案’达成共识，不构成区分度。
2. **摘要题 T2**：4 个模型的摘要文本高度相似（用词、句式几乎一致），均拿到 9/10（仅 1 个关键事实遗漏）。
3. **创作题 T3**：字数控制是关键。M3（269字）、V4-Pro（239字）超字数被扣分；M2.7（178字）、V4-Flash（180字）合规。
4. **推理题 T4（关键差异）**：M2.7 直接下‘无解’结论（错），M3 推理卡住没给答案（错），V4-Flash 和 V4-Pro 都用进位方程严谨推导出  $x=1, y=1$  唯一解并给出具体答案。
5. **性价比**：V4-Flash 在自动评分中**拿到第一**（29/30），且单次推理最便宜（\$0.14/\$0.28 per 1M tokens）；V4-Pro 贵 10 倍但表现不如 V4-Flash（26/30）。

## 8. 结论

---

基于 60% 自动分 + 40% 互评的加权综合：

- **V4-Pro** 综合 90.0/100
- **V4-Flash** 综合 89.3/100
- **M2.7** 综合 80.0/100
- **M3** 综合 68.0/100

**测试设计局限（必须告知）**：- 4 个任务样本量小，单题差异可由 1 分决定排名走向 - T1 代码是经典题，无区分度；T2 摘要任务简单 - T4 推理题我中途改了 3 次，题目设计经验不足 - 互评仅一轮，裁判之间也未做交叉验证 - 本次测试不构成生产选型依据，仅供粗略参考